

Diyabet Hastalığı Tahmin Modeli

Neden şelale modelini tercih ettik kısaca açıklayacak olursak şelale modelinin hangi durumlarda avantajlı olduğuna bakalım ;

Gereksinimler sıklıkla değişmiyorsa, gereksinimler açık ve netse, ortam stabilse ve kaynaklar mevcutsa, bu durumlarda şelale modelini kullanmak projeniz için daha iyi olacaktır. Bizim projemize baktığımızda veriler hastalardan alınacak ve buna göre bir model geliştirilecektir. Gereksinimler sıklıkla değişmiyor çünkü bir kişinin diyabet olup olmadığını belirlemeye çalışıyoruz. İleride sisteme hastalardaki farklı bir veri eklenebilir ve bu sistemimizin değişmesini gerektirmez. Bu yüzden sıklıkla değişmeyen bir sistemimiz var. Dolayısıyla, bizim projemizde şelale modelini kullanmak bizim için daha iyi olacaktır.

Bu getirdiği yararlı özelliklerin yanında getirdiği kötü özellik ise maalesef bir asamdan önceki aşamaya geri dönmek bu model de oldukça zordur bu nedenle günümüzde şelale modeline yatkın olan projelerde kullanılmaya devam ederken sektörün çoğu artık agile ya da farklı modellere geçildi.

Şelale Modeli Adımları



Şelale modeli, yazılım geliştirme sürecinin temel adımlarını sistematik bir şekilde ele alır. Her adım bir öncekinden bağımsız olarak tamamlanır ve sonraki aşamaya geçilir. Bu yapı sayesinde, projelerin düzenli ve kontrollü bir şekilde ilerlemesi sağlanır.

Proje Süreci

1

Gereksinim Analizi

Projenin ilk ve en önemli aşamalardan biridir ve odak noktamızdır çünkü ileri aşamalara gidebilmemiz için en doğru kararları burada vermemiz gerekmektedir. Bu aşama hastaların ihtiyaçlarını, sorunları ve sarf edilecek eforu anlamak için gereksinim analizi gerçekleştirdik.

2

Sistem Tasarımı

Gereksinim analizinden elde ettiğimiz bilgileri kullanarak, diyabet hastalığı tahmin modelinin mimarisini ve işleyişini tasarladık. Ve nasıl bir yapıya sahip olduğu anlaşılır ve bu dizaynlar detaylıca dokümana dökülmektedir.

3

Uygulama

Sistem tasarımını temel alarak, diyabet hastalığı tahmin modelini geliştirmeye başladık. Bu aşamada, makine öğrenmesi algoritmalarını seçtik, veri topluluğu hazırladık ve modeli eğittik. Ve sade, kullanıcı dostu bir arayüz tasarladık, böylece kullanıcılar kolay şekilde sonuçlara erişebilsin.

Gereksinim Analizi

Hasta İhtiyaçları

Hastaların en önem verdiği kısım, hastalığın erken teşhisidir. Hastalar, önce kendine ait bilgilerini günlük hayattaki beslenmesi ve fiziksel aktivitelerini söylemeli ve belirtilerin farkına varmadan diyabet risklerinin belirlenmesini ve gerekli önlemlerin alınmasını istemektedirler.

Sağlık Sistemi Beklentileri

Sağlık kurumları, diyabet hastalarının en iyi bakımını sağlamak ve sağlık hizmeti maliyetlerini azaltmak istemektedirler. Bu nedenle, diyabet hastalığını önceden tahmin edebilen ve rahatsızlığı önleyebilen çözümlere ihtiyaç duymaktadırlar.

Teknoloji Trendleri

Son yıllarda, makine öğrenmesi ve veri analitiği ilerlemeleri, bu gibi kronik hastalıkların çözüme ulaştırılmasında büyük etken sağlamaktadır. Erken teşhis, risk değerlendirmesi ve kişisel tedavi planlarının oluşturulmasında kullanılabilmektedir.

Sistem Tasarımı

1

Veri Toplama

Proje ekibimiz, diyabet hastalarından kapsamlı veriler topladı. Bu veriler, hastaların kendine ait bilgileri bilgileri, fiziksel aktiviteleri, yaşam tarzı alışkanlıkları ve laboratuvar sonuçlarını içermektedir. Böylece, daha güvenilir ve ele alınabilecek bir veri topluluğu elde ettik.

2

Veri İşleme ve Analiz

Toplanan verileri, makine öğrenmesi algoritmalarının kullanımına hazır hale getirdik. Veri temizleme, eksik değerler ve aykırı değerlerin tespiti gibi adımları gerçekleştirerek, modelin doğruluğunu ve performansını iyileştirdik.

3

Tahmin Modeli

Hastalığın tahmin modelini geliştirmek için, makine öğrenmesi algoritmalarını test ettik. En doğru ve yüksek performansı gösteren algoritmayı seçerek, modeli eğittik ve doğruladık. Yani model, diyabet hastası olup olamamasını yüzdesel olarak güvenilir şekilde tahmin etti.

Uygulama

1

Kullanıcı Dostu Arayüz

E kibimiz modeli, kullanıcıların kolaylıkla erişebileceği ve anlayabileceği bir arayüzle oluşturdu. Yani, hizmetliler ve hastalar, model sonuçlarını hızlı ve etkin bir şekilde değerlendirebilir.

2

Kişiselleştirilmiş Sonuçlar

Model, kullanıcıların kendine ait bilgileri, yaşam tarzı , günlük hayattaki fiziksel aktivitelerine göre ele alınarak o insana özel diyabet taşıma riski olup olmaması belirlenir. Yani genel olarak bu, hastaların kendi durumlarını daha iyi anlamalarına ve uygun önlemler almalarına yardımcı olur.

3

Önleyici Öneriler

Uygulamamız, diyabet riskini azaltmak için kullanıcılara özelleştirilmiş öneri ve rehberlik sağlamaktadır. Bu öneriler, yaşam tarzı değişiklikleri, fiziksel aktivite düzenlemesi ,diyet düzenlemeleri ve düzenli kontroller gibi konuları kapsamaktadır.

```
print(classification_report(y,y_pred))
```

	precision	recall	f1-score	support
0	0.79	0.90	0.84	500
1	0.74	0.55	0.63	268
accuracy			0.77	768
macro avg	0.76	0.72	0.73	768
weighted avg	0.77	0.77	0.77	768

Genel bir inceleme yaparsak 768 adet test verimizden 500 tanesi 0 yani hasta olmayanlar 268 tanesi 1 olarak gelmiş yani hasta olanlar. 0 değeri için %79 doğruluk oranımız varken 1 değeri için doğruluk oranımız %74 tür. Genel doğruluk oranımız ise %77'dir. .

```
loj_model.predict_proba(X)[0:10][:,  
#mesela 2.si 1 olma olasılığı çok d
```

```
array([[0.9167465 , 0.0832535 ],  
       [0.22496175, 0.77503825],  
       [0.92105964, 0.07894036],  
       [0.16807458, 0.83192542],  
       [0.79857716, 0.20142284],  
       [0.87973055, 0.12026945],  
       [0.27755404, 0.72244596],  
       [0.32068936, 0.67931064],  
       [0.9223939 , 0.0776061 ]])
```

Baştaki sütun 0 sınıfına aittir 1 e ait sınıflar sağ taraftakilerdir. Örnek verirsek 2. satırda 1 olma olasılığı yani hasta çıkma olasılığı çok düşük bir ihtimal yani 0.08 değeri çıkmıştır.

```
from sklearn.ensemble import RandomForestRegressor
rf_model=RandomForestRegressor(random_state=42).fit(X_train,y_train)
```

```
from sklearn.metrics import mean_squared_error
y_pred=rf_model.predict(X_test) #tahminler
np.sqrt(mean_squared_error(y_test,y_pred)) #hata kareler ortalaması
```

0.41561199854351333

```
rf_params={"max_depth":[2,3,5,8,10],
           "max_features":[2,5,8],
           "n_estimators":[10,500,1000],
           "min_samples_split":[2,5,10]}
```

```
rf_model_cv=GridSearchCV(rf_model,rf_params,cv=10,n_jobs=-1,verbose=2)
rf_model_cv.fit(X_train,y_train) #buralardan doğru değerleri çekip parametreye geçireceğiz
```

Fitting 10 folds for each of 135 candidates, totalling 1350 fits

```
GridSearchCV(cv=10, estimator=RandomForestRegressor(random_state=42), n_jobs=-1,
             param_grid={'max_depth': [2, 3, 5, 8, 10],
                           'max_features': [2, 5, 8],
                           'min_samples_split': [2, 5, 10],
                           'n_estimators': [10, 500, 1000]},
             verbose=2)
```

In a Jupyter environment, please rerun this cell to show the HTML representation or trust the notebook.
On GitHub, the HTML representation is unable to render, please try loading this page with nbviewer.org.

```
from sklearn.ensemble import RandomForestClassifier
rf_tuned=RandomForestClassifier(max_depth=10,max_features=8,min_samples_split=10,n_estimators=1000).fit(X_train,y_train)
```

```
y_pred=rf_tuned.predict(X_test)|
accuracy_score(y_test,y_pred) #ilkel skor test setinde %75 doğruluk oranı ile başarılı sonuç çıkmıştır
```

0.7532467532467533

Test ve Doğrulama

Veri Doğruluđu

Ekibimiz, toplanan verilerin güvenilirliđi ve kalitesini ayrıntılı şekilde inceledi. Veri kalitesi kontrolleri ve benzersiz vakaların tespiti gibi adımlar, modelin performansını önemli ölçüde iyileştirdi.

Model Performansı

Geliştirdiđimiz model, çeşitli test veri setleri üzerinde değerlendirildi. Doğruluk, titiz yaklaşım, özgüllük kullanarak modelin klinik uygulamalar için yeterli performans gösterdiđi doğrulandı.

Kullanılabilirlik

Son olarak, hizmetliler ve hastalar ile testler gerçekleştirerek, uygulamamızın kullanıcı dostu olduđunu ve hedef kitlenin ihtiyaçlarını karşıladığını doğruladık.

Kurulum

1

Altyapı Hazırlığı

Uygulamanın başarılı şekilde uygulanması için, güvenli bir altyapı oluşturduk. Bu oluşum, yüksek performanslı işlem gücünün çözümlerini içermektedir.

2

Entegrasyon

Uygulamanın, sağlık hizmetlerinde bilgi sistemleri ile sorunsuz bir şekilde entegre ettik. Bu sayede, kullanıcıların model sonuçlarına kolayca erişmesi ve hasta kayıtlarıyla eşleştirmesi sağlandı.

3

Kullanıcı Eğitimi

Hizmetliler, modelin iyi şekilde kullanmaları için eğitimler verdik. Bu eğitimler, modelin analiz etme, gelen verilerin hasta bakıma aktarılması ve sonuçların değerlendirilmesi konularını içermektedir.

Bakım



Veri Güncelleme

Hastalıkla alakalı veriler, zamanla değişen olaylar ve yeni çıkan argümanlar nedeniyle sürekli güncelleştirilme halinde olur. Yani bu sebeple, performansı maksimum düzeyde tutmak için sürekli şekilde veri güncelleme yapmamız gerekmektedir.



Model Güncelleme

Yeni veriler ışığında, diyabet hastalığı tahmin modelimizi periyodik olarak güncelliyor ve optimize ediyoruz. Bu sayede, modelin doğruluğunu ve klinik uygulamadaki etkinliğini sürekli iyileştiriyoruz.



Kullanıcı Desteği

Hizmetliler ve hastalar, model kullanımı sırasında sorunlar ve çözölemeyen akılda kalan sorularla karşılaşabilirler. Bu yüzden, onlara sürekli iletişim halinde olmak ve teknik destek sağlamak gerekir.



Sistem İzleme

Modelin güvenli şekilde, kesintisiz çalışmasını sağlamak için, sistem performansını ve güvenliğini sürekli izleme halindeyiz. Sorunlar erken tespit edilip çözüme ulaştırıyoruz.

Özet ve Sağlık Sektörüne Katkıları

Projenin Özeti

Proje bu hastalığın verimli şekilde sonuç alması ve erken teşhisin alınmasında, makine öğrenmesi altyapılı tahmin modeli geliştirilmiştir. Projenin her aşaması, sağlık hizmetlerinin ve hastaların ihtiyaçlarını doğrultusunda tasarlanmıştır.

Sağlık Sektörüne Katkıları

Diyabet hastalığı, kan şekerinde anormalliklere neden olan zararlı hastalıklardan biridir. Bu hastalığın erken teşhisi insan vücudunda oluşabilecek organ bozulmalarını engeller. Yapay zekâ tabanlı çalışmalar medikal alanda etkin bir şekilde gerçekleştirilmektedir.

Makine öğrenmesine dayalı bilgisayar destekli uzman sistemler bu hastalığın erken teşhisi için oldukça faydalıdır .

Geliştirdiğimiz tahmin modeli, sağlık hizmetlerine ve hastalarına oldukça önem arz edecektir. Risklerin azaltılması ,maliyetlerin indirgenmesi.. Model kullanımının yaygınlaşmasıyla da herkesin genel olarak sağlık durumunda da iyiye gitme durumu olacaktır.